


2024211008 이현섭



GloVe dataset 개요



GloVe 데이터셋 소개


(<https://nlp.stanford.edu/projects/glove/>)

단어에 대한 벡터 표현을 얻기 위한 비지도 학습 알고리즘


- 단어 임베딩을 생성하기 위한 방법 중 하나
- 스탠포드 대학에서 만든 데이터

단어 임베딩을 학습하기 위해 통계 정보를 기반으로 하는 기법

- 주로 말뭉치에 나타나는 단어들 간의 동시 등장 빈도를 활용한다.
- 표현은 단어 벡터 공간의 흥미로운 선형 하위 구조를 보여준다.



GloVe를 통해
쌍을 비교한 모습



회사-CEO 간의 쌍을 보여주는
모습

GloVe 데이터 (txt)

```
the -0.038194 -0.24487 0.72812 -0.39961 0.083172 0.043953 -0.39141 0.3344 -0.57545 0.087459 0.28787 -0.0673
, -0.10767 0.11053 0.59812 -0.54361 0.67396 0.10663 0.038867 0.35481 0.06351 -0.094189 0.15786 -0.81665 0.1
. -0.33979 0.20941 0.46348 -0.64792 -0.38377 0.038034 0.17127 0.15978 0.46619 -0.019169 0.41479 -0.34349 0.
of -0.1529 -0.24279 0.89837 0.16996 0.53516 0.48784 -0.58826 -0.17982 -1.3581 0.42541 0.15377 0.24215 0.134
to -0.1897 0.050024 0.19084 -0.049184 -0.089737 0.21006 -0.54952 0.098377 -0.20135 0.34241 -0.092677 0.161
and -0.071953 0.23127 0.023731 -0.50638 0.33923 0.1959 -0.32943 0.18364 -0.18057 0.28963 0.20448 -0.5496 0.
in 0.085703 -0.22201 0.16569 0.13373 0.38239 0.35401 0.01287 0.22461 -0.43817 0.50164 -0.35874 -0.34983 0.0
a -0.27086 0.044006 -0.02026 -0.17395 0.6444 0.71213 0.3551 0.47138 -0.29637 0.54427 -0.72294 -0.0047612 0.
" -0.30457 -0.23645 0.17576 -0.72854 -0.28343 -0.2564 0.26587 0.025309 -0.074775 -0.3766 -0.057774 0.12159
's 0.58854 -0.2025 0.73479 -0.68338 -0.19675 -0.1802 -0.39177 0.34172 -0.60561 0.63816 -0.26695 0.36486 -0.
for -0.14401 0.32554 0.14257 -0.099227 0.72536 0.19321 -0.24188 0.20223 -0.89599 0.15215 0.035963 -0.59513
- -1.2557 0.61036 0.56793 -0.96596 -0.45249 -0.071696 0.57122 -0.31292 -0.43814 0.90622 0.06961 -0.053104 0
that -0.093337 0.19043 0.68457 -0.41548 -0.22777 -0.11803 -0.095434 0.19613 0.17785 -0.020244 -0.055409 0.3
on -0.21863 -0.42664 0.5196 0.0043103 0.58045 -0.10873 -0.37726 0.4566 -0.60627 -0.075773 0.11306 0.17703 0
is -0.54264 0.41476 1.0322 -0.40244 0.46691 0.21816 -0.074864 0.47332 0.080996 -0.22079 -0.12808 -0.1144 0.
was 0.13717 -0.54287 0.19419 -0.29953 0.17545 0.084672 0.67752 0.098295 -0.035611 0.21334 0.51663 0.20687 0
said -0.13128 -0.452 0.043399 -0.99798 -0.21053 -0.95868 -0.24609 0.48413 0.18178 0.475 -0.22305 0.30064 0.
with -0.43608 0.39104 0.51657 -0.13861 0.2029 0.50723 -0.012544 0.22948 -0.6316 0.21199 -0.018043 -0.39364
he 0.1225 -0.058833 0.23658 -0.28877 -0.028181 0.31524 0.070229 0.16447 -0.027623 0.25214 0.21174 -0.059674
as -0.32721 0.096446 0.34244 -0.44327 0.30535 -0.042016 -0.071235 -0.31036 -0.22557 -0.181 -0.29088 -0.6154
it -0.30664 0.16821 0.98511 -0.33606 -0.2416 0.16186 -0.053496 0.4301 0.57342 -0.071569 0.36101 0.26729 0.2
by -0.20875 -0.1174 0.26478 -0.28339 0.19584 0.7446 -0.03887 0.028499 -0.44252 -0.30426 0.27133 -0.51907 0.
```

- 첫 번째 열은 해당 단어의 텍스트를 나타냄.
- 나머지 열은 해당 단어의 임베딩 벡터(1번째 줄에서는 ‘the’라는 단어를 나타내고, 그 뒤의 숫자들은 해당 단어의 임베딩 벡터를 나타냄)

GloVe 데이터셋 특징

글로벌 통계 정보 활용

- 전체 말뭉치에 대한 통계 정보를 사용, 단어 간의 관련성을 파악.

비지도 학습

- 비지도 학습 방법으로 작동되며, 레이블이나 추가 정보 없이도 단어 간의 의미 관계를 파악할 수 있다.

동시 등장 행렬

- 말뭉치 내 단어들 간의 동시 등장 행렬을 활용하여 단어 임베딩을 학습.
- 행렬은 말뭉치 내 단어들이 함께 등장한 횟수를 담음.

분산 표현 학습

- 각 단어를 고차원 벡터로 표현하여 단어의 의미를 나타냄.
- 분산 표현은 단어 간의 유사성을 측정하는데 사용됨.

GloVe 데이터셋 예시

최근접 이웃 특징

- 의미적 유사성을 측정하여 효과적인 방법을 제공
- 예를 들어 frog라는 목표 단어에 가까운 단어들을 보여줌(frogs, toad 등)

선형 부분 구조

- ‘man’은 ‘woman’과 유사하게 여겨질 수 있음.
- 이 대비되는 개념을 미묘한 차이를 통해 양적으로 나타내기 위해서는 모델이 단어 쌍에 하나의 숫자가 아닌 더 많은 정보를 연관시켜야 함.
- 두 단어의 연결로부터 지정된 의미를 최대한 포착할 수 있도록 함.

(남자 - 여자, 왕 - 여왕, 형제 - 자매)

이러한 특징으로 인해 GloVe는 자연어 처리분야에서 주로 사용, 단어 간의 의미적 유사성을 파악하는데 도움이 된다.

GloVe 데이터셋 예시

훈련

- 어떤 말뭉치에서 단어들이 함께 출현하는 빈도를 기록한 전역 단어-단어 행렬의 0이 아닌 항목들로 훈련됨.
- 이 행렬을 채우려면 전체 말뭉치를 한 번 통과하여 통계를 수집함.

모델

- 본질적으로 가중 최소 제곱 목적을 가진 로그-이중 선형 모델

이러한 특징으로 인해 GloVe는 자연어 처리분야에서 주로 사용, 단어 간의 의미적 유사성을 파악하는데 도움이 된다.

Probability and Ratio	$k = solid$	$k = gas$	$k = water$	$k = fashion$
$P(k ice)$	1.9×10^{-4}	6.6×10^{-5}	3.0×10^{-3}	1.7×10^{-5}
$P(k steam)$	2.2×10^{-5}	7.8×10^{-4}	2.2×10^{-3}	1.8×10^{-5}
$P(k ice)/P(k steam)$	8.9	8.5×10^{-2}	1.36	0.96

어떤 말뭉치에서 대상 단어 ice와 steam의 발생 확률을 다양한 표본 단어와 함께 고려해본 것.